

Machine Learning clásico

Clase 5, parte 1 de 2 · Regresión y regularización

Diseño y Optimización de Sistemas Térmicos · ILN223

Mijail Littin

Universidad Técnica Federico Santa María · 2026-2

Brunton y Kutz, Data-Driven Science and Engineering, cap. 4

Plan de la clase


Clase 5

- 1 Regresión y regularización
- 2 Generalización, clasificación y PCA

Hoy

- Machine Learning como optimización
- Regresión lineal y ecuaciones normales
- Mínimos cuadrados como proyección
- Ridge, LASSO y Elastic Net
- Geometría de las normas L1 y L2
- Sistemas sobre y subdeterminados


Machine Learning como optimización



Clase 3. Simulamos el sistema para un diseño dado.

Clase 4. Buscamos el mejor diseño resolviendo $\min_x f(x)$.

Machine Learning como optimización



Clase 3. Simulamos el sistema para un diseño dado.

Clase 4. Buscamos el mejor diseño resolviendo $\min_x f(x)$.


Entrenar un modelo es resolver

$$\min_w \mathcal{L}(w)$$

La función objetivo es el **error** del modelo sobre los datos.

Machine Learning como optimización


Aprendizaje supervisado



Pares entrada y salida $(\dot{m}_i, T_{s,i})$, se aprende a predecir T_s para un caudal nuevo


Machine Learning como optimización

Aprendizaje supervisado



Pares entrada y salida $(\dot{m}_i, T_{s,i})$, se aprende a predecir T_s para un caudal nuevo

Aprendizaje no supervisado



Sin etiquetas, se descubren grupos, por ejemplo regímenes de operación de una planta

Mínimos cuadrados regularizados

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}}$$

A , matriz de características, m datos por n parámetros

x , parámetros del modelo, lo que se aprende

b , observaciones medidas o simuladas

Mínimos cuadrados regularizados

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1, LASSO}}$$

A , matriz de características, m datos por n parámetros

x , parámetros del modelo, lo que se aprende

b , observaciones medidas o simuladas

Mínimos cuadrados regularizados

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1, LASSO}} + \underbrace{\lambda_2 \|x\|_2^2}_{\text{Penalización L2, Ridge}}$$

A , matriz de características, m datos por n parámetros

x , parámetros del modelo, lo que se aprende

b , observaciones medidas o simuladas

Mínimos cuadrados regularizados

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1, LASSO}} + \underbrace{\lambda_2 \|x\|_2^2}_{\text{Penalización L2, Ridge}}$$

$\lambda_1 = \lambda_2 = 0$

Mínimos cuadrados, regresión lineal

Hoy, ahora

$\lambda_1 > 0 \text{ o } \lambda_2 > 0$

Ridge, LASSO y Elastic Net


Hoy, segunda mitad

Elegir λ

Validación cruzada con datos nuevos


Mañana

Regresión lineal



- Entrada, caudal $\dot{m}$ entre 0,05 y 0,50 kg/s
- Salida medida, temperatura T_s del agua
- Veinte mediciones con ruido de sensor

Regresión lineal




$$T_s \approx x_0 + x_1 z + x_2 z^2$$

$$z = \frac{\dot{m} - 0,275}{0,225}$$

Lineal en los parámetros x y curvo en z . El caudal escalado z va de -1 a 1 .

Regresión lineal




$$T_s \approx x_0 + x_1 z + x_2 z^2$$

$$z = \frac{\dot{m} - 0,275}{0,225}$$

$$\begin{bmatrix} 1 & -0,91 & 0,83 \\ 1 & -0,90 & 0,81 \\ 1 & -0,89 & 0,80 \\ \vdots & \vdots & \vdots \\ 1 & 1,00 & 1,00 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 41,10 \\ 42,60 \\ 42,81 \\ \vdots \\ 71,09 \end{bmatrix}$$

Regresión lineal




$$T_s \approx x_0 + x_1 z + x_2 z^2$$

$$z = \frac{\dot{m} - 0,275}{0,225}$$

$$\begin{matrix} & A & & x & & b \\ \begin{bmatrix} 1 & -0,91 & 0,83 \\ 1 & -0,90 & 0,81 \\ 1 & -0,89 & 0,80 \\ \vdots & \vdots & \vdots \\ 1 & 1,00 & 1,00 \end{bmatrix} & \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} & = & \begin{bmatrix} 41,10 \\ 42,60 \\ 42,81 \\ \vdots \\ 71,09 \end{bmatrix} \\ m \times n = 20 \times 3 & 3 & & 20 \end{matrix}$$

Más ecuaciones que incógnitas. Ningún x cumple las veinte a la vez.

Regresión lineal




Mejor recta, con $x_2 = 0$

$$r_i = b_i - (Ax)_i$$

$$\|Ax - b\|_2^2 = \sum_{i=1}^{20} r_i^2$$


$$\sum r_i^2 = 379,2 (\text{°C})^2$$

Regresión lineal



$$L(x) = \|Ax - b\|_2^2$$
$$= (Ax - b)^T (Ax - b)$$

Regresión lineal




$$L(x) = \|Ax - b\|_2^2$$

$$= (Ax - b)^T (Ax - b)$$

$$= x^T A^T A x - 2 b^T A x + b^T b$$

Regresión lineal



$$L(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|_2^2$$


$$= (\mathbf{Ax} - \mathbf{b})^T (\mathbf{Ax} - \mathbf{b})$$

$$= \mathbf{x}^T \mathbf{A}^T \mathbf{Ax} - 2 \mathbf{b}^T \mathbf{Ax} + \mathbf{b}^T \mathbf{b}$$

$$\nabla L = 2 \mathbf{A}^T \mathbf{Ax} - 2 \mathbf{A}^T \mathbf{b}$$

$$\nabla(\mathbf{x}^T \mathbf{M} \mathbf{x}) = 2 \mathbf{M} \mathbf{x} \text{ con } \mathbf{M} \text{ simétrica, } \nabla(\mathbf{c}^T \mathbf{x}) = \mathbf{c}$$

Regresión lineal



$$L(x) = \|Ax - b\|_2^2$$

$$= (Ax - b)^T (Ax - b)$$

$$= x^T A^T A x - 2 b^T A x + b^T b$$

$$\nabla L = 2 A^T A x - 2 A^T b$$


$$= 2 A^T (Ax - b) = 0$$

$$A^T A \hat{x} = A^T b$$

Pregunta de control

¿De qué tamaño es $A^T A$ si medimos mil caudales?

Regresión lineal




$$\hat{x}_{\text{parábola}} = (A^T A)^{-1} A^T b = \begin{bmatrix} 66,34 \\ 15,01 \\ -11,89 \end{bmatrix}$$

$$A^T A \hat{x} = A^T b$$

Ecuaciones normales

Regresión lineal



$$\hat{x}_{\text{parábola}} = (A^T A)^{-1} A^T b = \begin{bmatrix} 66,34 \\ 15,01 \\ -11,89 \end{bmatrix}$$


$$A^T A \hat{x} = A^T b$$

Ecuaciones normales

Clase 3. $A\theta = b$ venía de discretizar la ecuación de calor en una barra.

Hoy. A y b vienen de datos observados. El álgebra lineal es la misma.

Función de pérdida cuadrática




$$T_s \approx x_0 + x_1 z$$

$$L(x_0, x_1) = \|Ax - b\|_2^2$$

Cada punto del piso es una recta. La altura es su error.

Función de pérdida cuadrática




$$x_{k+1} = x_k - \alpha \nabla L(x_k)$$

$$\alpha = 0,04$$

$$k = 20 \quad x_k = (61,70; 14,91)$$

El paso cambia de lado en x_0 , la dirección de mayor curvatura.

Función de pérdida cuadrática



$$x_{k+1} = x_k - \alpha \nabla L(x_k)$$

$$\alpha = 0,04$$


$$k = 20 \quad x_k = (61,70; 14,91)$$

$$A^T A \hat{x} = A^T b \Rightarrow \hat{x}_{\text{recta}} = (61,70; 14,91)$$

Pérdida convexa, un solo mínimo. Las ecuaciones normales llegan en un paso.

Mínimos cuadrados como proyección

Ejemplo ilustrativo




Tres mediciones en $z = -1, 0$ y 1 , y una recta. $m = 3$ datos, $n = 2$ parámetros.

$$\underbrace{\begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_0 \\ x_1 \end{bmatrix}} \approx \underbrace{\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}}_b$$

Cada eje es una medición. Las columnas a_1 y a_2 son vectores de $\mathbb{R}^3$.

Mínimos cuadrados como proyección

Ejemplo ilustrativo



Tres mediciones en $z = -1, 0$ y 1 , y una recta. $m = 3$ datos, $n = 2$ parámetros.


$$\underbrace{\begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_0 \\ x_1 \end{bmatrix}} \approx \underbrace{\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}}_b$$

$$Ax = x_0 a_1 + x_1 a_2$$

Todas las predicciones posibles forman un plano.

Mínimos cuadrados como proyección

Ejemplo ilustrativo



$$\underbrace{\begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_0 \\ x_1 \end{bmatrix}}_b \approx \underbrace{\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}}_b$$


$$Ax = x_0 a_1 + x_1 a_2$$

Todas las predicciones posibles forman un plano.

b queda fuera del plano. El punto del plano más cercano a b es su proyección ortogonal $A\hat{x}$.

Mínimos cuadrados como proyección

Ejemplo ilustrativo



$$\underbrace{\begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_0 \\ x_1 \end{bmatrix}}_b \approx \underbrace{\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}}_b$$

$$Ax = x_0 a_1 + x_1 a_2$$


Todas las predicciones posibles forman un plano.

b queda fuera del plano. El punto del plano más cercano a b es su proyección ortogonal $A\hat{x}$.

De canto, el residuo r es perpendicular al plano.

Mínimos cuadrados como proyección

Ejemplo ilustrativo



$$a_1^T r = 0, \quad a_2^T r = 0$$


$$A^T r = A^T (b - A\hat{x}) = 0$$

$$A^T A \hat{x} = A^T b$$

Las mismas ecuaciones normales

Mínimos cuadrados como proyección

Ejemplo ilustrativo



$$a_1^T r = 0, \quad a_2^T r = 0$$

$$A^T r = A^T (b - A\hat{x}) = 0$$

$$A^T A \hat{x} = A^T b$$

Las mismas ecuaciones normales

$$A^T A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}, \quad A^T b = \begin{bmatrix} 6 \\ 1 \end{bmatrix}$$

$$\hat{x} = (2; 0,5), \quad A\hat{x} = (1,5; 2; 2,5)$$

$$r = (-0,5; 1; -0,5), \quad A^T r = 0$$

Pregunta de control

¿Cuánto vale $a_2^T r$ con estos números?


Implementación de mínimos cuadrados

```
import numpy as np

def ols_ecuaciones_normales(A, b):
    return np.linalg.solve(A.T @ A, A.T @ b)

def ols_pseudo_inversa(A, b):
    return np.linalg.pinv(A) @ b
```

El código forma $A^T A$ y solve resuelve el sistema de 3×3 .



Implementación de mínimos cuadrados

```
import numpy as np



def ols_ecuaciones_normales(A, b):
    return np.linalg.solve(A.T @ A, A.T @ b)

def ols_pseudo_inversa(A, b):
    return np.linalg.pinv(A) @ b
```

El código forma $A^T A$ y solve resuelve el sistema de 3×3 .

La función pinv usa la descomposición en valores singulares de A , sin formar $A^T A$.

$$\max |\hat{x}_{\text{solve}} - \hat{x}_{\text{pinv}}| \approx 7 \cdot 10^{-14}$$



Implementación de mínimos cuadrados

```
import numpy as np

def ols_ecuaciones_normales(A, b):
    return np.linalg.solve(A.T @ A, A.T @ b)

def ols_pseudo_inversa(A, b):
    return np.linalg.pinv(A) @ b
```

Doble precisión guarda unas 16 cifras. Con $\kappa \approx 10^{10}$ se pierden unas 10.

$$\kappa(A^T A) = \kappa(A)^2$$

	$\kappa(A)$	$\kappa(A^T A)$
$\dot{m}$, grado 2	68,3	$4,7 \cdot 10^3$
z, grado 2	3,4	11,5
$\dot{m}$, grado 5	$1,3 \cdot 10^5$	$1,6 \cdot 10^{10}$
z, grado 5	63,3	$4,0 \cdot 10^3$

Implementación de mínimos cuadrados

```
import numpy as np

def ols_ecuaciones_normales(A, b):
    return np.linalg.solve(A.T @ A, A.T @ b)

def ols_pseudo_inversa(A, b):
    return np.linalg.pinv(A) @ b
```

Escalar y usar pinv reducen el error de redondeo.
El ruido de b se amplifica en $\hat{x}$ como $1/\sigma_{\min}$ de A .

$$\|Ax - b\|_2^2 + \lambda_2 \|x\|_2^2$$

Penalizar los coeficientes grandes

$$\kappa(A^T A) = \kappa(A)^2$$

	$\kappa(A)$	$\kappa(A^T A)$
$\dot{m}$, grado 2	68,3	$4,7 \cdot 10^3$
z , grado 2	3,4	11,5
$\dot{m}$, grado 5	$1,3 \cdot 10^5$	$1,6 \cdot 10^{10}$
z , grado 5	63,3	$4,0 \cdot 10^3$

Regularización Ridge, LASSO y Elastic Net

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1}} + \underbrace{\lambda_2 \|x\|_2^2}_{\text{Penalización L2}}$$

Mínimos cuadrados (OLS)

$$\lambda_1 = 0, \lambda_2 = 0$$

Solución cerrada $\hat{x} = (A^T A)^{-1} A^T b$

Regularización Ridge, LASSO y Elastic Net

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1}} + \underbrace{\lambda_2 \|x\|_2^2}_{\text{Penalización L2}}$$

Mínimos cuadrados (OLS)

$$\lambda_1 = 0, \lambda_2 = 0$$

Solución cerrada $\hat{x} = (A^T A)^{-1} A^T b$

Ridge

$$\lambda_1 = 0, \lambda_2 > 0$$

Achica coeficientes grandes y estabiliza.
Solución cerrada

Regularización Ridge, LASSO y Elastic Net

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1}} + \underbrace{\lambda_2 \|x\|_2^2}_{\text{Penalización L2}}$$

Mínimos cuadrados (OLS)

$$\lambda_1 = 0, \lambda_2 = 0$$

Solución cerrada $\hat{x} = (A^T A)^{-1} A^T b$

Ridge

$$\lambda_1 = 0, \lambda_2 > 0$$

Achica coeficientes grandes y estabiliza.
Solución cerrada

LASSO

$$\lambda_1 > 0, \lambda_2 = 0$$

Deja coeficientes exactamente en cero. Sin
fórmula cerrada para el vector completo

Regularización Ridge, LASSO y Elastic Net

$$\hat{x} = \arg \min_x \underbrace{\|Ax - b\|_2^2}_{\text{Error de ajuste}} + \underbrace{\lambda_1 \|x\|_1}_{\text{Penalización L1}} + \underbrace{\lambda_2 \|x\|_2^2}_{\text{Penalización L2}}$$

Mínimos cuadrados (OLS)

$$\lambda_1 = 0, \lambda_2 = 0$$

Solución cerrada $\hat{x} = (A^T A)^{-1} A^T b$

Ridge

$$\lambda_1 = 0, \lambda_2 > 0$$

Achica coeficientes grandes y estabiliza.
Solución cerrada

LASSO

$$\lambda_1 > 0, \lambda_2 = 0$$

Deja coeficientes exactamente en cero. Sin
fórmula cerrada para el vector completo

Elastic Net

$$\lambda_1 > 0, \lambda_2 > 0$$

Estabilidad de Ridge y selección de variables
de LASSO

Ridge en forma cerrada

$$J(x) = \|Ax - b\|_2^2 + \lambda_2 x^T x$$

$$\nabla J = 2A^T(Ax - b) + 2\lambda_2 x = 0$$

El primer término ya lo conocemos de las ecuaciones normales. El nuevo es $\nabla(\lambda_2 x^T x) = 2\lambda_2 x$.

Ridge en forma cerrada

$$J(x) = \|Ax - b\|_2^2 + \lambda_2 x^T x$$


$$\nabla J = 2A^T(Ax - b) + 2\lambda_2 x = 0$$

El primer término ya lo conocemos de las ecuaciones normales. El nuevo es $\nabla(\lambda_2 x^T x) = 2\lambda_2 x$.

$$(A^T A + \lambda_2 I) \hat{x} = A^T b$$

Dividimos por 2 y juntamos los términos en x . Con $\lambda_2 = 0$ vuelven las ecuaciones normales.

Valores propios de la matriz de Ridge



Los 10 valores propios de $A^T A$, polinomio de grado 9 en z

$$(A^T A + \lambda_2 I) \hat{x} = A^T b$$


Valores propios de $A^T A + \lambda_2 I = \sigma_i^2 + \lambda_2$
 σ_i son los valores singulares de A

$$\lambda_2 = 0$$

$$\sigma_{\min}^2 + \lambda_2 = 4,3 \cdot 10^{-6}$$

$$\kappa = \frac{\sigma_{\max}^2 + \lambda_2}{\sigma_{\min}^2 + \lambda_2} = 6,6 \cdot 10^6$$

Valores propios de la matriz de Ridge



Los 10 valores propios de $A^T A$, polinomio de grado 9 en z

$$(A^T A + \lambda_2 I) \hat{x} = A^T b$$

Valores propios de $A^T A + \lambda_2 I = \sigma_i^2 + \lambda_2$
 σ_i son los valores singulares de A


$$\lambda_2 = 0,10$$

$$\sigma_{\min}^2 + \lambda_2 = 0,10$$

$$\kappa = \frac{\sigma_{\max}^2 + \lambda_2}{\sigma_{\min}^2 + \lambda_2} = 284$$

Coeficientes con y sin Ridge

$$(A^T A + \lambda_2 I) \hat{x} = A^T b$$



Con $\lambda_2 = 0,1$ el mayor coeficiente baja de 111,3 a 8,6

Implementación de Ridge y LASSO

```
def ridge(A, b, lam):  
    n = A.shape[1]  
    return np.linalg.solve(A.T @ A + lam*np.eye(n), A.T @ b)  
  
def lasso(A, b, lam, n_iter=200):  
    x = np.zeros(A.shape[1])  
    for _ in range(n_iter):  
        for j in range(A.shape[1]):  
            r = b - A @ x + A[:, j]*x[j]  
            rho = A[:, j] @ r  
            z = A[:, j] @ A[:, j]  
            x[j] = np.sign(rho)*max(abs(rho) - lam/2, 0)/z  
    return x
```

Ridge es un solo sistema lineal, la fórmula de la lámina anterior.

$$(A^T A + \lambda_2 I) \hat{x} = A^T b$$

Implementación de Ridge y LASSO

```
def ridge(A, b, lam):
    n = A.shape[1]
    return np.linalg.solve(A.T @ A + lam*np.eye(n), A.T @ b)

def lasso(A, b, lam, n_iter=200):
    x = np.zeros(A.shape[1])
    for _ in range(n_iter):
        for j in range(A.shape[1]):
            r = b - A @ x + A[:, j]*x[j]
            rho = A[:, j] @ r
            z = A[:, j] @ A[:, j]
            x[j] = np.sign(rho)*max(abs(rho) - lam/2, 0)/z
    return x
```

Pasada 2

x_1	x_2	x_3	x_4	x_5	x_6
2,54	0,00	-1,45	0,00	0,73	0,00

Descenso por coordenadas con los seis sensores del ejemplo final y $\lambda_1 = 20$. Se ajusta una componente x_j con las demás fijas.

Implementación de Ridge y LASSO

```
def ridge(A, b, lam):  
    n = A.shape[1]  
    return np.linalg.solve(A.T @ A + lam*np.eye(n), A.T @ b)  
  
def lasso(A, b, lam, n_iter=200):  
    x = np.zeros(A.shape[1])  
    for _ in range(n_iter):  
        for j in range(A.shape[1]):  
            r = b - A @ x + A[:, j]*x[j]  
            rho = A[:, j] @ r  
            z = A[:, j] @ A[:, j]  
            x[j] = np.sign(rho)*max(abs(rho) - lam/2, 0)/z  
    return x
```

$$r = b - \sum_{k \neq j} a_k x_k$$

$$\rho = a_j^T r$$

$$z = a_j^T a_j$$

a_j es la columna j de A y z su norma al cuadrado. El residuo r deja fuera el aporte de x_j .

Implementación de Ridge y LASSO

```
def ridge(A, b, lam):  
    n = A.shape[1]  
    return np.linalg.solve(A.T @ A + lam*np.eye(n), A.T @ b)  
  
def lasso(A, b, lam, n_iter=200):  
    x = np.zeros(A.shape[1])  
    for _ in range(n_iter):  
        for j in range(A.shape[1]):  
            r = b - A @ x + A[:, j]*x[j]  
            rho = A[:, j] @ r  
            z = A[:, j] @ A[:, j]  
            x[j] = np.sign(rho)*max(abs(rho) - lam/2, 0)/z  
    return x
```

$$\min_{x_j} \|r - a_j x_j\|^2 + \lambda_1 |x_j|$$
$$= z x_j^2 - 2\rho x_j + \lambda_1 |x_j| + \text{cte.}$$

Implementación de Ridge y LASSO

```
def ridge(A, b, lam):  
    n = A.shape[1]  
    return np.linalg.solve(A.T @ A + lam*np.eye(n), A.T @ b)  
  
def lasso(A, b, lam, n_iter=200):  
    x = np.zeros(A.shape[1])  
    for _ in range(n_iter):  
        for j in range(A.shape[1]):  
            r = b - A @ x + A[:, j]*x[j]  
            rho = A[:, j] @ r  
            z = A[:, j] @ A[:, j]  
            x[j] = np.sign(rho)*max(abs(rho) - lam/2, 0)/z  
    return x
```

$$\min_{x_j} \|r - a_j x_j\|^2 + \lambda_1 |x_j|$$


$$= z x_j^2 - 2\rho x_j + \lambda_1 |x_j| + \text{cte.}$$

$$\text{Si } x_j > 0, \quad 2z x_j - 2\rho + \lambda_1 = 0$$

$$x_j = \frac{\text{sign}(\rho) \max(|\rho| - \lambda_1/2; 0)}{z}$$

Si $|\rho| \leq \lambda_1/2$ el mínimo está en $x_j = 0$ exacto.

Umbral suave de LASSO y contracción de Ridge




- LASSO, $\text{sign}(\rho) \max(|\rho| - \lambda_1/2; 0)/z$
- Ridge, $\rho/(z + \lambda_2)$
- Zona muerta $|\rho| \leq \lambda_1/2$

$$z = 1, \quad \lambda_1 = \lambda_2 = 2,0$$

En $\rho = 3$, LASSO da $x_j = 2$ y Ridge $x_j = 1$.
En $\rho = 0,8$, LASSO da $x_j = 0$.

Umbral suave de LASSO y contracción de Ridge



■ LASSO, $\text{sign}(\rho) \max(|\rho| - \lambda_1/2; 0)/z$

■ Ridge, $\rho/(z + \lambda_2)$


■ Zona muerta $|\rho| \leq \lambda_1/2$

$$z = 1, \quad \lambda_1 = \lambda_2 = 4,0$$

Pregunta de control

Con $\lambda_1 = \lambda_2 = 4$ y $\rho = 3$, ¿qué valor dan LASSO y Ridge?

Umbral suave de LASSO y contracción de Ridge



■ LASSO, $\text{sign}(\rho) \max(|\rho| - \lambda_1/2; 0)/z$

■ Ridge, $\rho/(z + \lambda_2)$

■ Zona muerta $|\rho| \leq \lambda_1/2$

$$z = 1, \quad \lambda_1 = \lambda_2 = 4,0$$


Pregunta de control

Con $\lambda_1 = \lambda_2 = 4$ y $\rho = 3$, ¿qué valor dan LASSO y Ridge?

LASSO da $x_j = 3 - 2 = 1$. Ridge da $x_j = 3/5 = 0,6$.


Caminos de coeficientes, seis sensores candidatos

Datos sintéticos, $m = 40$, tres sensores en la ley, en naranja




Coeficientes no nulos, 0 de 6

Camino de coeficientes, seis sensores candidatos



Coeficientes no nulos, 0 de 6



Ningún coeficiente se queda en cero

Geometría de las normas L1 y L2

$$\min_x \|Ax - b\|_2^2 + \lambda \|x\|$$

$$\iff$$


$$\min_x \|Ax - b\|_2^2 \quad \text{sujeto a} \quad \|x\| \leq c$$

λ más grande $\longleftrightarrow$ c más chico


Ridge usa $\|x\|_2^2$ y LASSO $\|x\|_1$. En el ejemplo que sigue, $c = 1$ equivale a $\lambda_2 = 0,79$ en Ridge y a $\lambda_1 = 1,48$ en LASSO

Geometría de las normas L1 y L2

Ridge, $\|x\|_2 \leq 1$, un círculo




LASSO, $\|x\|_1 \leq 1$, un diamante




Ejemplo ilustrativo

Geometría de las normas L1 y L2

Ridge, $\|x\|_2 \leq 1$, un círculo




LASSO, $\|x\|_1 \leq 1$, un diamante



Ejemplo ilustrativo


Geometría de las normas L1 y L2

Ridge, $\|x\|_2 \leq 1$, un círculo



$\hat{x} = (0,90; 0,43)$ Los dos no nulos

LASSO, $\|x\|_1 \leq 1$, un diamante




$\hat{x} = (1; 0)$ $x_2 = 0$ exacto

Ejemplo ilustrativo


Geometría de las normas L1 y L2

Ridge, $\|x\|_2 \leq 1$, un círculo



$$\hat{x}_2 = 0,43$$

LASSO, $\|x\|_1 \leq 1$, un diamante




$$\hat{x}_2 = 0,00$$

Ejemplo ilustrativo


Geometría de las normas L1 y L2

Ridge, $\|x\|_2 \leq 1$, un círculo



x_{OLS}^* sobre una recta, un coeficiente nulo


LASSO, $\|x\|_1 \leq 1$, un diamante



x_{OLS}^* en una zona rosada, un coeficiente nulo

Ejemplo ilustrativo

Normas L1 y L2 en tres dimensiones



Ridge, $\|x\|_2 \leq 1$ es una esfera


Las superficies de nivel del error son elipsoides con centro en x_{OLS}^* .

$$\hat{x} = (0,90; 0,32; 0,30)$$

Ningún coeficiente nulo

Ejemplo ilustrativo, $x_{OLS}^* = (1,2; 0,5; 0,3)$

Normas L1 y L2 en tres dimensiones



Ridge, $\|x\|_2 \leq 1$ es una esfera

Las superficies de nivel del error son elipsoides con centro en x_{OLS}^* .


$$\hat{x} = (0,90; 0,32; 0,30)$$

Ningún coeficiente nulo

Ridge reduce la norma de x .

Ejemplo ilustrativo, $x_{OLS}^* = (1,2; 0,5; 0,3)$

Normas L1 y L2 en tres dimensiones



LASSO, $\|x\|_1 \leq 1$ es un octaedro


Las superficies de nivel del error son elipsoides con centro en x_{OLS}^* .

$$\hat{x} = (1; 0; 0)$$

Dos coeficientes exactamente en cero

Ejemplo ilustrativo, $x_{OLS}^* = (1,2; 0,5; 0,3)$

Normas L1 y L2 en tres dimensiones



LASSO, $\|x\|_1 \leq 1$ es un octaedro

Las superficies de nivel del error son elipsoides con centro en x_{OLS}^* .

$$\hat{x} = (1; 0; 0)$$


Dos coeficientes exactamente en cero

En un vértice se anulan dos coeficientes. En una arista, uno.

Ejemplo ilustrativo, $x_{OLS}^* = (1,2; 0,5; 0,3)$

Sistemas sobre y subdeterminados


Bien determinado, $m = n$



A invertible, solución única
 $x = A^{-1}b$


Sistemas sobre y subdeterminados

Bien determinado, $m = n$



A invertible, solución única
 $x = A^{-1}b$


Sobredeterminado, $m > n$



Más ecuaciones que incógnitas,
en general sin solución exacta.
Mínimos cuadrados


Sistemas sobre y subdeterminados

Bien determinado, $m = n$




A invertible, solución única
 $x = A^{-1}b$

Sobredeterminado, $m > n$




Más ecuaciones que incógnitas,
en general sin solución exacta.
Mínimos cuadrados

Subdeterminado, $m < n$



Más incógnitas que ecuaciones,
infinitas soluciones. Norma
mínima


Norma mínima y Ridge con λ_2 pequeño



$$A = \begin{pmatrix} 1 & 2 \end{pmatrix}, \quad b = 4$$

$$x_{\min} = A^T(AA^T)^{-1}b = (0,8; 1,6)$$

Norma mínima y Ridge con λ_2 pequeño



$$A = \begin{pmatrix} 1 & 2 \end{pmatrix}, \quad b = 4$$


$$x_{\min} = A^T(AA^T)^{-1}b = (0,8; 1,6)$$

$$x_{\lambda_2} = (A^T A + \lambda_2 I)^{-1} A^T b$$

λ_2	x_{λ_2}	$\ x_{\lambda_2} - x_{\min}\ $
1	(0,667; 1,333)	$3,0 \cdot 10^{-1}$
0,1	(0,784; 1,569)	$3,5 \cdot 10^{-2}$
0,01	(0,798; 1,597)	$3,6 \cdot 10^{-3}$
0,001	(0,800; 1,600)	$3,6 \cdot 10^{-4}$


Sistemas sobre y subdeterminados

Bien determinado, $m = n$




A invertible, solución única
 $x = A^{-1}b$

Sobredeterminado, $m > n$



Más ecuaciones que incógnitas,
en general sin solución exacta.
Mínimos cuadrados

Subdeterminado, $m < n$



Más incógnitas que ecuaciones,
infinitas soluciones. Norma
mínima

En Machine Learning A casi siempre es alta, muchos más datos que parámetros

Próxima clase

Hipótesis de hoy

- Modelo lineal en los parámetros
- Error cuadrático, ruido de medición de media cero
- Datos sintéticos de un intercambiador con ley conocida

Próxima clase, generalización

- Sobreajuste y error con datos nuevos
- Validación cruzada para elegir el grado y λ
- Clasificar fallas y comprimir sensores