

Machine Learning clásico

Clase 5, parte 2 de 2 · Generalización, clasificación y PCA

Diseño y Optimización de Sistemas Térmicos · ILN223

Mijail Littin

Universidad Técnica Federico Santa María · 2026-2

Brunton y Kutz, Data-Driven Science and Engineering, cap. 4

Plan de la clase

Clase 5


1 Regresión y regularización

2 Generalización, clasificación y PCA

Hoy

- Sobreajuste y subajuste
- Validación cruzada k -fold
- Frontera de Pareto entre error y complejidad
- Clasificación con regresión logística
- Reducción de dimensionalidad con PCA

Sobreajuste y subajuste




$$\hat{T}_s = x_0 + x_1 z + x_2 z^2$$

$$z = \frac{\dot{m} - 0,275}{0,225}$$

$$ECM = \frac{1}{m} \sum_{i=1}^m (\hat{T}_{s,i} - T_{s,i})^2$$

$$ECM_{\text{entrenamiento}} = \frac{41,3}{20} = 2,06 \text{ (}^{\circ}\text{C)}^2$$

Sobreajuste y subajuste



$$\hat{T}_s = x_0 + x_1 z + x_2 z^2$$

$$z = \frac{\dot{m} - 0,275}{0,225}$$

$$ECM = \frac{1}{m} \sum_{i=1}^m (\hat{T}_{s,i} - T_{s,i})^2$$


$$ECM_{\text{entrenamiento}} = \frac{41,3}{20} = 2,06 \text{ (°C)}^2$$

$$ECM_{\text{datos nuevos}} = 3,86 \text{ (°C)}^2$$


200 mediciones nuevas del mismo equipo, nunca usadas para ajustar. Existen porque los datos son sintéticos, en una planta no las tenemos.

Sobreajuste y subajuste

$$\hat{T}_s = x_0 + x_1 z + \dots + x_g z^g \quad g = 5$$




■ Entrenamiento ■ Datos nuevos, referencia
ECM [(°C)²], escala log




Pregunta de control. Si solo miramos el error de entrenamiento, ¿qué grado elegirían?

Sobreajuste y subajuste

$$\hat{T}_s = x_0 + x_1 z + \dots + x_g z^g \quad g = 12$$




Entrenamiento Datos nuevos, referencia
ECM [(°C)²], escala log




Sobreajuste y subajuste

$$\hat{T}_s = x_0 + x_1 z + \dots + x_g z^g \quad g = 12$$




■ Entrenamiento ■ Datos nuevos, referencia
ECM [(°C)²], escala log




El error de entrenamiento siempre baja. El de datos nuevos tiene un mínimo.

Sobreajuste y subajuste

Seis conjuntos de 20 mediciones del mismo equipo, un ajuste por conjunto




■ Entrenamiento ■ Datos nuevos, referencia
ECM [(°C)²], escala log



El error de entrenamiento siempre baja. El de datos nuevos tiene un mínimo.


Sobreajuste y subajuste

Seis conjuntos de 20 mediciones del mismo equipo, un ajuste por conjunto



$$g = 10$$

■ Entrenamiento ■ Datos nuevos, referencia
ECM [(°C)²], escala log




En la práctica no tenemos la curva de datos nuevos.


Validación cruzada




- 1 Dividir los datos en $k = 5$ pliegues (folds) al azar.




Validación cruzada




- 1 Dividir los datos en $k = 5$ pliegues (folds) al azar.
- 2 Entrenar con $k - 1$ pliegues y validar con el restante.




Validación cruzada



- 1 Dividir los datos en $k = 5$ pliegues (folds) al azar.
- 2 Entrenar con $k - 1$ pliegues y validar con el restante.
- 3 Repetir k veces, rotando el pliegue de validación.




Validación cruzada





4 Promediar los k errores de validación.



$$CV(g) = \frac{1}{k} \sum_{i=1}^k ECM_i \quad CV(3) = 0,73 \text{ (}^{\circ}\text{C)}^2$$



Validación cruzada




Validación cruzada



Validación cruzada


Pregunta de control. En un caso real guardamos parte de las mediciones como conjunto de prueba. ¿Por qué no elegir el grado con ese conjunto?



Validación cruzada

Pregunta de control. En un caso real guardamos parte de las mediciones como conjunto de prueba. ¿Por qué no elegir el grado con ese conjunto?

Si la prueba elige el modelo, su error deja de medir datos nuevos. La prueba se usa una sola vez, al final.



Implementación de la validación cruzada

```
def k_fold_error(z, T, grado, k=5):  
    rng = np.random.default_rng(0)  
    folds = np.array_split(rng.permutation(len(z)), k)  
    errores = []  
    for i in range(k):  
        val = folds[i]  
        train = np.hstack(folds[:i] + folds[i+1:])  
        coef = np.polyfit(z[train], T[train], grado)  
        pred = np.polyval(coef, z[val])  
        errores.append(np.mean((pred - T[val])**2))  
    return np.mean(errores)
```

rng.permutation(20)

folds[0]	4	19	6	2
folds[1]	13	16	3	11
folds[2]	10	8	0	12
folds[3]	7	5	18	17
folds[4]	14	9	1	15

Implementación de la validación cruzada

```
def k_fold_error(z, T, grado, k=5):  
    rng = np.random.default_rng(0)  
    folds = np.array_split(rng.permutation(len(z)), k)  
    errores = []  
    for i in range(k):  
        val = folds[i]  
        train = np.hstack(folds[:i] + folds[i+1:])  
        coef = np.polyfit(z[train], T[train], grado)  
        pred = np.polyval(coef, z[val])  
        errores.append(np.mean((pred - T[val])**2))  
    return np.mean(errores)
```

	rng.permutation(20)				errores
folds[0]	4	19	6	2	1,36
folds[1]	13	16	3	11	0,05
folds[2]	10	8	0	12	0,94
folds[3]	7	5	18	17	1,04
folds[4]	14	9	1	15	0,26

grado = 3

Implementación de la validación cruzada

```
def k_fold_error(z, T, grado, k=5):  
    rng = np.random.default_rng(0)  
    folds = np.array_split(rng.permutation(len(z)), k)  
    errores = []  
    for i in range(k):  
        val = folds[i]  
        train = np.hstack(folds[:i] + folds[i+1:])  
        coef = np.polyfit(z[train], T[train], grado)  
        pred = np.polyval(coef, z[val])  
        errores.append(np.mean((pred - T[val])**2))  
    return np.mean(errores)
```

```
grados = range(1, 13)  
err_cv = [k_fold_error(z, T, g) for g in grados]  
g_opt = grados[np.argmin(err_cv)]
```

	rng.permutation(20)				errores
folds[0]	4	19	6	2	1,36
folds[1]	13	16	3	11	0,05
folds[2]	10	8	0	12	0,94
folds[3]	7	5	18	17	1,04
folds[4]	14	9	1	15	0,26


grado = 3

$\text{np.mean(errores)} = 0,73$

Implementación de la validación cruzada

```
def k_fold_error(z, T, grado, k=5):  
    rng = np.random.default_rng(0)  
    folds = np.array_split(rng.permutation(len(z)), k)  
    errores = []  
    for i in range(k):  
        val = folds[i]  
        train = np.hstack(folds[:i] + folds[i+1:])  
        coef = np.polyfit(z[train], T[train], grado)  
        pred = np.polyval(coef, z[val])  
        errores.append(np.mean((pred - T[val])**2))  
    return np.mean(errores)
```

```
grados = range(1, 13)  
err_cv = [k_fold_error(z, T, g) for g in grados]  
g_opt = grados[np.argmin(err_cv)]
```




Implementación de la validación cruzada


```
def k_fold_ridge(z, T, lam, k=5):  
    rng = np.random.default_rng(0)  
    folds = np.array_split(rng.permutation(len(z)), k)  
    errores = []  
    for i in range(k):  
        val = folds[i]  
        train = np.hstack(folds[:i] + folds[i+1:])  
        A = np.vander(z[train], 11, increasing=True)  
        x = np.linalg.solve(A.T @ A + lam * D, A.T @ T[train])  
        pred = np.vander(z[val], 11, increasing=True) @ x  
        errores.append(np.mean((pred - T[val])**2))  
    return np.mean(errores)
```

$D = \text{np.diag}([0.0] + [1.0] * 10)$

El término constante x_0 no se penaliza.




Frontera de Pareto entre error y complejidad



Cada punto es un modelo, un subconjunto de los términos $z, z^2, \dots, z^8$ más la constante.

256 modelos, cada uno evaluado con los mismos 5 pliegues. La complejidad es el número de términos, sin importar la potencia.


Frontera de Pareto entre error y complejidad



Un modelo está **dominado** si otro tiene igual o menos términos y menor error, o menos términos e igual error.

El polinomio completo de grado 8 tiene 9 términos y $CV = 1,07$. Los modelos en la zona sombreada lo dominan.


Frontera de Pareto entre error y complejidad



La **frontera de Pareto** reúne los modelos no dominados. Ninguno mejora un objetivo sin empeorar el otro.

1 término	110,05
2 términos	22,28
3 términos	2,74
4 términos	0,48
5 términos	0,40

Frontera de Pareto entre error y complejidad




Lex parsimoniae (navaja de Occam).

Entre modelos con error similar, elegir el más simple.

Franja desde el mínimo hasta el mínimo más un error estándar de los 20 errores por punto de validación. 8 modelos caen en ella, el más simple tiene 4 términos.

$$\hat{T}_s = x_0 + x_1 z + x_4 z^4 + x_5 z^5$$

Regresión logística



Rodamiento de una bomba, temperatura T_r y vibración v medidas en 120 revisiones.


■ $y = 0$, sin falla

■ $y = 1$, falla

Buscamos la probabilidad de falla para una revisión nueva.


$$x_1 = \frac{T_r - 60}{10} \quad x_2 = \frac{v - 3,5}{1,5}$$

Regresión logística




$$s = w_1 x_1 + w_2 x_2 + w_0$$

$$p = \sigma(s) = \frac{1}{1 + e^{-s}} \in (0, 1)$$



Notación del código de la clase. Variables x_1, x_2 , una fila de X por revisión. Parámetros w y el término constante w_0 , que muchos códigos llaman b . Etiquetas y . $Xw + w_0$ es el Ax de ayer con una columna de unos.


Regresión logística



Altura de la superficie, $p = \sigma(w_1x_1 + w_2x_2 + w_0)$, con los pesos tras 500 iteraciones.

Revisiones con falla dibujadas a altura 1 y sin falla a altura 0.

Regresión logística




$$p = 0,5 \iff e^{-s} = 1 \iff s = 0$$

$$2,06 x_1 + 2,58 x_2 - 0,35 = 0$$

La frontera de decisión es una recta en el plano de las variables.


Coeficientes tras 500 iteraciones del entrenamiento de la lámina siguiente.

Regresión logística




$$L(w) = -\frac{1}{m} \sum_{i=1}^m \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right]$$

Entropía cruzada. Es convexa en (w, w_0) , todo mínimo local es global. El error cuadrático con la sigmoide no es convexo.




Regresión logística



$$L(w) = -\frac{1}{m} \sum_{i=1}^m \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right]$$

Una neurona artificial calcula
 $p = \sigma(w_1 x_1 + w_2 x_2 + w_0)$. La clase 6 conecta
muchas en capas.



Implementación de la regresión logística

```
def sigmoid(s):  
    return 1.0 / (1.0 + np.exp(-s))
```

```
w, w0 = np.zeros(2), 0.0
```

```
lr = 0.1
```

```
for _ in range(500):  
    p = sigmoid(X @ w + w0)  
    grad_w = X.T @ (p - y) / len(y)  
    grad_w0 = np.mean(p - y)  
    w -= lr * grad_w  
    w0 -= lr * grad_w0
```

$$w = \mathbf{0}, w_0 = 0 \Rightarrow p_i = \sigma(0) = 0,5$$

$$L = -\ln 0,5 = \ln 2 = 0,693$$

El término constante w_0 se llama w_0 . Las etiquetas y se llaman y . El paso α de la clase 4 se llama lr .

Implementación de la regresión logística

```
def sigmoid(s):  
    return 1.0 / (1.0 + np.exp(-s))  
  
w, w0 = np.zeros(2), 0.0  
lr = 0.1  
for _ in range(500):  
    p = sigmoid(X @ w + w0)  
    grad_w = X.T @ (p - y) / len(y)  
    grad_w0 = np.mean(p - y)  
    w -= lr * grad_w  
    w0 -= lr * grad_w0
```

$$\sigma'(s) = \frac{e^{-s}}{(1 + e^{-s})^2} = \sigma(s) (1 - \sigma(s))$$

Implementación de la regresión logística

```
def sigmoid(s):  
    return 1.0 / (1.0 + np.exp(-s))  
  
w, w0 = np.zeros(2), 0.0  
lr = 0.1  
for _ in range(500):  
    p = sigmoid(X @ w + w0)  
    grad_w = X.T @ (p - y) / len(y)  
    grad_w0 = np.mean(p - y)  
    w -= lr * grad_w  
    w0 -= lr * grad_w0
```

$$\sigma'(s) = \frac{e^{-s}}{(1 + e^{-s})^2} = \sigma(s) (1 - \sigma(s))$$

$$\ell_i = -[y_i \ln p_i + (1 - y_i) \ln(1 - p_i)], \quad p_i = \sigma(s_i)$$

$$\frac{\partial \ell_i}{\partial s_i} = -\left[\frac{y_i}{p_i} - \frac{1 - y_i}{1 - p_i}\right] p_i(1 - p_i) = p_i - y_i$$

Implementación de la regresión logística

```
def sigmoid(s):  
    return 1.0 / (1.0 + np.exp(-s))  
  
w, w0 = np.zeros(2), 0.0  
lr = 0.1  
for _ in range(500):  
    p = sigmoid(X @ w + w0)  
    grad_w = X.T @ (p - y) / len(y)  
    grad_w0 = np.mean(p - y)  
    w -= lr * grad_w  
    w0 -= lr * grad_w0
```

$$\frac{\partial \ell_i}{\partial s_i} = - \left[\frac{y_i}{p_i} - \frac{1 - y_i}{1 - p_i} \right] p_i (1 - p_i) = p_i - y_i$$

$$\nabla_w L = \frac{1}{m} \sum_i (p_i - y_i) \mathbf{x}_i = \frac{1}{m} \mathbf{X}^T (\mathbf{p} - \mathbf{y})$$

$$\frac{\partial L}{\partial w_0} = \frac{1}{m} \sum_i (p_i - y_i)$$

Mínimos cuadrados, ayer

$$\nabla_x \| \mathbf{A} \mathbf{x} - \mathbf{b} \|^2 = 2 \mathbf{A}^T (\mathbf{A} \mathbf{x} - \mathbf{b})$$



Implementación de la regresión logística

```
def sigmoid(s):  
    return 1.0 / (1.0 + np.exp(-s))  
  
w, w0 = np.zeros(2), 0.0  
lr = 0.1  
for _ in range(500):  
    p = sigmoid(X @ w + w0)  
    grad_w = X.T @ (p - y) / len(y)  
    grad_w0 = np.mean(p - y)  
    w -= lr * grad_w  
    w0 -= lr * grad_w0
```

Iteración 500

$L = 0,187$

Exactitud (entrenamiento) 93,3 %



Implementación de la regresión logística

Tras 500 iteraciones



$$w_1 = 2,06 \quad w_2 = 2,58 \quad w_0 = -0,35$$

Mismo descenso de gradiente
de la clase 4, con otra pérdida.

Iteración 500

$$L = 0,187$$

Exactitud (entrenamiento) 93,3 %




Análisis de componentes principales

Tres termocuplas en una placa calefaccionada,
150 lecturas.


$$X \in \mathbb{R}^{150 \times 3}, \quad \text{fila } i = (T_1, T_2, T_3)_i$$

$$\bar{\mathbf{x}} = \begin{pmatrix} 46,0 \\ 43,0 \\ 39,1 \end{pmatrix} ^\circ\text{C}$$

Datos sintéticos



Análisis de componentes principales



Tres termocuplas en una placa calefaccionada, 150 lecturas.


$$X \in \mathbb{R}^{150 \times 3}, \quad \text{fila } i = (T_1, T_2, T_3)_i$$

$$\bar{\mathbf{x}} = \begin{pmatrix} 46,0 \\ 43,0 \\ 39,1 \end{pmatrix} ^\circ\text{C}$$

$$X_c = X - \mathbf{1} \bar{\mathbf{x}}^T$$

Cada columna queda con promedio cero. La nube se traslada al origen.

Análisis de componentes principales




$$X_c = U \Sigma V^T$$

Filas de V^T , direcciones principales. Diagonal de Σ , valores singulares σ_i . Largo de cada eje $\pm 2\sigma_i / \sqrt{150 - 1}$, dos desviaciones estándar.

$$\sigma_1 = 100,2 \quad \sigma_2 = 20,3 \quad \sigma_3 = 5,9$$

Pregunta de control. Con estos valores singulares, ¿cuántas direcciones hacen falta para describir las lecturas?


Análisis de componentes principales



$$X_c = U \Sigma V^T$$


Filas de V^T , direcciones principales. Diagonal de Σ , valores singulares σ_i . Largo de cada eje $\pm 2\sigma_i / \sqrt{150 - 1}$, dos desviaciones estándar.

$$\sigma_1 = 100,2 \quad \sigma_2 = 20,3 \quad \sigma_3 = 5,9$$



$$\frac{\sigma_i^2}{\sum_j \sigma_j^2}$$


Análisis de componentes principales



$$X_c V_{(2)} \in \mathbb{R}^{150 \times 2}, \quad V_{(2)} = [\mathbf{v}_1 \ \mathbf{v}_2]$$

Segmentos rojos, distancia de cada lectura al plano, dibujada 5 veces más larga. Cada lectura se proyecta sobre el plano de PC1 y PC2. Dos números en vez de tres, se pierde el 0,3 % de la varianza.

Análisis de componentes principales



$$X_c V_{(2)} \in \mathbb{R}^{150 \times 2}, \quad V_{(2)} = [\mathbf{v}_1 \ \mathbf{v}_2]$$

Segmentos rojos, distancia de cada lectura al plano, dibujada 5 veces más larga. Cada lectura se proyecta sobre el plano de PC1 y PC2. Dos números en vez de tres, se pierde el 0,3 % de la varianza.

$$\mathbf{v}_1 = \begin{pmatrix} 0,67 \\ 0,57 \\ 0,47 \end{pmatrix} \quad \mathbf{v}_2 = \begin{pmatrix} -0,63 \\ 0,11 \\ 0,77 \end{pmatrix}$$

PC1, las tres suben juntas, la carga de calefacción.

PC2, T_1 baja y T_3 sube, el gradiente a lo largo de la placa.

Próxima clase

Hipótesis de hoy

- Datos de entrenamiento, validación y prueba independientes y del mismo proceso
- Frontera de decisión lineal entre las clases
- Estructura de los datos descrita por direcciones lineales, PCA

Clase 6, redes neuronales

- Componer capas lineales con no linealidades
- El mismo entrenamiento, $\min_{\theta} L$, con θ los parámetros de la red
- Redes informadas por la física (PINN)